

การวิเคราะห์ผลเรดาร์หยั่งทะลุพื้น (GPR) สำหรับการตรวจจบบ่อ ใต้ผิวดินด้วยการเรียนรู้ของเครื่อง Machine Learning-Enhanced Ground Penetrating Radar Analysis for Subsurface Cavity Detection

ศุภวุฒิ ทวีสุขโคตรม¹ สมโพธิ อยู่ไว^{2,*} และ วรัช ก้องกิจกุล³
Mitsumasa Yamashina⁴ José Rodrigues Neto⁵ and Jun Shinohara⁶

^{1,2,3} ภาควิชาวิศวกรรมโยธา คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี กรุงเทพมหานคร

^{4,6} Center for Disaster Management Informatics Research, Ehime University, Matsuyama, Japan

⁵ Research & Development Department, Canaan Geo Research, Co., Ltd., Matsuyama, Japan

*Corresponding author; E-mail address sompote.you@kmutt.ac.th

บทคัดย่อ

การตรวจจบบ่อใต้ผิวดินจากข้อมูลเรดาร์หยั่งทะลุพื้น (GPR) เป็นประเด็นสำคัญในงานตรวจสอบโครงสร้างพื้นฐานทางถนนในพื้นที่เมือง โดยเฉพาะในกรุงเทพมหานครซึ่งมีลักษณะชั้นดินเหนียวอ่อนและระดับน้ำใต้ดินสูง อันเป็นเงื่อนไขที่ท้าทายต่อการแปลผลสัญญาณเรดาร์ งานวิจัยนี้เปรียบเทียบสมรรถนะของแบบจำลองตรวจจบบ่อวัตถุในตระกูล YOLOv12 และ YOLOv26 ทั้งในสภาวะการเทรนจาก Random initialization และการใช้ Pretrained weights จาก COCO รวมถึงแบบจำลองผสมที่บูรณาการ DINOv3 เข้ากับสถาปัตยกรรม YOLO สำหรับการตรวจจบบ่อจากภาพ B-scan โดยกำหนดเป็นปัญหาการตรวจจบบ่อวัตถุแบบคลาสเดียว ชุดข้อมูลที่ประกอบด้วยภาพ B-scan จำนวน 1,391 ภาพ จาก 4 แหล่งหลัก ได้แก่ ข้อมูลภาคสนามจากกรุงเทพมหานคร ข้อมูลภาคสนามจากประเทศญี่ปุ่น ข้อมูลจากแพลตฟอร์ม Roboflow Universe และข้อมูลสังเคราะห์ที่สร้างด้วยโปรแกรม gprMax ผลการทดลองแสดงว่า YOLOv26s ที่ใช้ pretrained weights ให้สมรรถนะสูงสุด ด้วยค่า mAP@0.5 = 0.581, Precision = 0.820 และ F1-score = 0.594 ขณะที่แบบจำลองผสม YOLO-DINOv3 ให้ผลเพิ่มขึ้นจาก YOLOv12 เล็กน้อยแต่ยังไม่สามารถเทียบเท่า YOLOv26s ได้ เนื่องจาก domain mismatch ระหว่าง representation ของ DINOv3 กับลักษณะเฉพาะของสัญญาณ GPR ผลการศึกษาชี้ให้เห็นว่า YOLOv26s pretrained มีความสมดุลที่ดีระหว่างความแม่นยำและศักยภาพในการนำไปประยุกต์ใช้ในงานตรวจสอบโครงสร้างพื้นฐานทางถนนในพื้นที่เมืองได้จริง

คำสำคัญ: เรดาร์หยั่งทะลุพื้น, การตรวจจบบ่อวัตถุแบบคลาสเดียว, YOLO, การตรวจจบบ่อใต้ผิวดิน, การเรียนรู้ของเครื่อง

Abstract

Subsurface cavity detection from Ground Penetrating Radar (GPR) data is an important issue in urban road infrastructure inspection, particularly in Bangkok, where soft clay layers and a high groundwater table create challenging conditions for radar signal interpretation. This study compares the performance of object detection models in the YOLOv12 and YOLOv26 families,

trained under both random initialization and with pretrained weights from COCO, as well as hybrid models integrating DINOv3 into the YOLO architecture for cavity detection from B-scan images, formulated as a single-class object detection problem. The dataset consists of 1,391 B-scan images from four main sources: field data from Bangkok, field data from Japan, data from the Roboflow Universe platform, and synthetic data generated using gprMax. The experimental results show that YOLOv26s with pretrained weights achieved the highest performance, with mAP@0.5 = 0.581, Precision = 0.820, and F1-score = 0.594. Although the YOLO-DINOv3 hybrid models showed slight improvement over YOLOv12, they were still unable to match the performance of YOLOv26s due to the domain mismatch between DINOv3 representations and the distinctive characteristics of GPR signals. The findings indicate that pretrained YOLOv26s provides the best overall balance and has strong potential for practical application in urban road infrastructure inspection.

Keywords: GPR, Single-Class Object Detection, You Only Look Once, Subsurface Cavity Detection, Machine Learning

1. คำนำ

โพรงใต้ผิวดินเป็นความผิดปกติใต้ผิวดินที่อาจส่งผลกระทบต่อความมั่นคงและความปลอดภัยของโครงสร้างพื้นฐานทางถนน โดยเฉพาะในพื้นที่เมือง ปัญหานี้อาจเกิดจากการชะล้างของดิน การรั่วซึมของท่อใต้ดิน [1] หรือการเสื่อมสภาพของโครงสร้างชั้นทาง และหากตรวจพบไม่ทันเวลา อาจนำไปสู่การทรุดตัวของผิวทางและความเสียหายต่อโครงสร้าง รวมถึงการเกิดอุบัติเหตุและความเสี่ยงต่อผู้ใช้งาน โดยในประเทศไทยมีการประยุกต์ใช้เครื่องมือเรดาร์หยั่งทะลุพื้น (GPR) เพื่อตรวจจบบ่อโพรงใต้ผิวดินในเขตกรุงเทพมหานครแล้ว ซึ่งสะท้อนถึงความสำคัญของปัญหานี้ในบริบทเมืองจริง [2]

เรดาร์หยั่งทะลุพื้น หรือ Ground Penetrating Radar (GPR) เป็นเทคโนโลยีการสำรวจแบบไม่ทำลายสภาพพื้นผิวที่ได้รับความนิยมในการ

ตรวจสอบสภาพใต้ผิวดิน เนื่องจากสามารถส่งคลื่นแม่เหล็กไฟฟ้าลงสู่ตัวกลางและบันทึกสัญญาณสะท้อนกลับจากความแตกต่างของคุณสมบัติไดอิเล็กทริกของวัสดุใต้ผิวดินได้ [3] ข้อมูลจาก GPR สามารถนำเสนอได้หลายรูปแบบ โดยภาพ B-scan เป็นรูปแบบที่นิยมใช้ในการวิเคราะห์ความผิดปกติใต้ผิวดิน [4] อย่างไรก็ตาม การแปลผลข้อมูลภาคสนามยังทำได้ยากเนื่องจากมักมีสัญญาณรบกวนและความไม่สม่ำเสมอของชั้นดิน จึงยังต้องอาศัยผู้เชี่ยวชาญในการตีความ [5] ส่งผลให้การประเมินมีข้อจำกัดทั้งด้านเวลาและความสม่ำเสมอของผลลัพธ์ นอกจากนี้ ลักษณะความผิดปกติในภาพ B-scan ยังแตกต่างกันตามชนิดวัสดุ ความลึก และสภาพแวดล้อมใต้ผิวดิน [6] ทำให้การจำแนกข้อมูลจริงมีความซับซ้อนมากขึ้น ดังนั้น จึงมีการนำเทคนิคการประมวลผลข้อมูลและปัญญาประดิษฐ์ [7] มาใช้เพื่อเพิ่มความรวดเร็วและความน่าเชื่อถือในการวิเคราะห์ข้อมูล GPR


ในช่วงที่ผ่านมา พบว่ามีการประยุกต์ใช้ Machine Learning และ Deep Learning กับข้อมูล GPR มากขึ้น เพื่อช่วยลดข้อจำกัดของการวิเคราะห์ด้วยมนุษย์และเพิ่มความรวดเร็วในการตรวจจับความผิดปกติจากภาพ B-scan มีการนำ YOLOv3 มาใช้ตรวจจับโครงร่างใต้ผิวดินจากภาพ GPR B-scan แสดงให้เห็นศักยภาพของแนวทางการตรวจจับวัตถุสำหรับข้อมูล GPR [7] ต่อมา มีการประยุกต์ใช้ YOLOv5 ร่วมกับข้อมูลภาคสนามและข้อมูลสังเคราะห์จาก gprMax [8] ต่อมา มีการเสนอการผสมผสาน MHUnet-YOLOv8 [9] เพื่อปรับปรุงคุณภาพสัญญาณก่อนการตรวจจับ อีกทั้งมีการพัฒนา SESM-YOLO [10] ซึ่งเป็นงานวิจัยเชิงประยุกต์ด้านการตรวจจับวัตถุด้วย Deep Learning สำหรับข้อมูล GPR โดยปรับปรุงจาก YOLOv8n ให้เป็นแบบจำลองขนาดเล็ก เพื่อใช้ตรวจจับความเสียหายหรือความผิดปกติที่ซ่อนอยู่ใต้ผิวดินจากภาพ GPR เช่น บริเวณโครงหรือชั้นใต้ผิวดินที่มีลักษณะผิดปกติ ได้อย่างมีประสิทธิภาพมากขึ้น งานวิจัยเหล่านี้สะท้อนแนวโน้มการพัฒนาแบบจำลองให้เหมาะกับข้อมูล GPR มากขึ้น ทั้งด้านแบบจำลองและข้อมูลหลายแหล่งร่วมกัน

แม้งานวิจัยก่อนหน้าจะสะท้อนศักยภาพของการประยุกต์ใช้แบบจำลองตรวจจับวัตถุกับข้อมูล GPR แต่ส่วนใหญ่ยังใช้ข้อมูลภาคสนามจากต่างประเทศ [7-9] อีกทั้งพื้นที่กรุงเทพมหานครโดยทั่วไปพบชั้นดินเหนียวอ่อนมากถึงอ่อน [11] ที่มีความหนาประมาณ 10–20 m [12] และในพื้นที่ชั้นดินเหนียวอ่อนกรุงเทพฯ มีรายงานว่าระดับน้ำใต้ดินอยู่ตื้นประมาณ 0.5–1.0 m ใต้ผิวดิน [13] ขณะที่การตรวจจับโครงใต้ผิวดินด้วย GPR มีความลึกที่มีประสิทธิภาพประมาณ 0.5–3.0 m [14] ระดับน้ำใต้ดินดังกล่าวจึงอาจซ้อนทับกับช่วงความลึกของเป้าหมายที่ต้องการตรวจจับ ส่งผลให้ชั้นดินตื้นมีความชื้นสูง และทำให้คุณสมบัติทางไฟฟ้าของดินเปลี่ยนแปลง โดยเฉพาะค่าคงที่ไดอิเล็กทริกสัมพัทธ์ (Relative permittivity) และค่าการนำไฟฟ้า (Electrical conductivity) ซึ่งมีผลต่อความเร็ว การสะท้อน และการลดทอนของสัญญาณเรดาร์ ทำให้การตรวจจับโครงจากข้อมูล GPR ภาคสนามมีความซับซ้อนมากขึ้น [6] ดังนั้น เพื่อให้การสำรวจด้วย GPR มีประสิทธิภาพดีขึ้น ควรดำเนินการในช่วงที่พื้นผิวและชั้นดินตื้นไม่เปียกชื้นมากเกินไป รวมถึงหลีกเลี่ยงการสำรวจขณะฝนตกหรือหลังฝนตกใหม่ๆ เนื่องจากความชื้นสูงอาจทำให้สัญญาณเรดาร์ลดทอนลงและลดความชัดเจนของผลการตรวจจับโครงใต้ผิวดิน

งานวิจัยนี้มุ่งศึกษาศักยภาพของแบบจำลอง YOLOv12, YOLOv26 และแบบจำลองที่ผสมผสาน YOLO กับ DINOv3 สำหรับตรวจจับโครงใต้ผิวดินจากข้อมูล GPR แบบ B-scan เนื่องจาก B-scan แสดงภาพหน้าตัดใต้ผิวดินตามแนวสำรวจ ทำให้เห็นตำแหน่ง ความลึก และลักษณะความผิดปกติได้ชัดเจนกว่า A-scan ซึ่งเป็นสัญญาณหนึ่งมิติ ส่วน C-scan แม้แสดงการกระจายตัวเชิงพื้นที่ได้ดี แต่ต้องใช้ข้อมูลหลายแนวสำรวจและมีขั้นตอน

ประมวลผลซับซ้อนกว่า จึงเลือกใช้ B-scan เป็นข้อมูลภาพสำหรับฝึกแบบจำลองในการศึกษานี้


2. วิธีดำเนินการวิจัย




รูปที่ 1 ขั้นตอนการทำงานของโครงข่ายประสาทเทียม

2.1 ข้อมูลที่ใช้ในการศึกษา

ข้อมูลจาก 4 แหล่งหลัก ประกอบด้วยข้อมูลภาคสนามจากกรุงเทพมหานคร, ข้อมูลภาคสนามจากประเทศญี่ปุ่น, ข้อมูลจากแหล่งข้อมูลสาธารณะบนแพลตฟอร์ม Roboflow Universe และข้อมูลสังเคราะห์ที่สร้างขึ้นด้วยโปรแกรม gprMax [15] เพื่อเพิ่มความหลากหลายของข้อมูล ทั้งนี้เพื่อสนับสนุนการแปลผลข้อมูลให้มีความรวดเร็ว สมบูรณ์ และเหมาะสมต่อการประยุกต์ใช้ในงานตรวจสอบโครงสร้างพื้นฐานทางถนน แต่ละแหล่งมีลักษณะสัญญาณของโครงข่ายแตกต่างกันอย่างชัดเจน โดยจากรูปที่ 2(ก) ข้อมูลจากกรุงเทพมหานครมักปรากฏลักษณะไฮเพอร์โบลาที่ไม่สมมาตรและมีสัญญาณรบกวนพื้นหลังค่อนข้างมาก ขณะที่ข้อมูลจากประเทศญี่ปุ่น จากรูปที่ 2(ข) มีรูปไฮเพอร์โบลาที่แผ่กว้างในแนวนอนและกลมกลืนกับพื้นหลังมากกว่า ส่วนข้อมูลจาก Roboflow Universe จากรูปที่ 2(ค) มีลักษณะสัญญาณที่เด่นชัดและมีคอนทราสต์สูงกว่า ขณะที่ข้อมูลสังเคราะห์ gprMax จากรูปที่ 2(ง) แสดงรูปไฮเพอร์โบลาที่สมมาตร คมชัด และมีสัญญาณรบกวนน้อยกว่า ความแตกต่างดังกล่าวช่วยเพิ่มความหลากหลายของข้อมูลทั้งในด้านรูปแบบชั้นดิน ระดับสัญญาณรบกวน ความคมชัดของลักษณะไฮเพอร์โบลา ตลอดจนความลึกและขนาดของโครงข่าย ซึ่งเป็นประโยชน์ต่อการฝึกแบบจำลองให้เรียนรู้รูปแบบสัญญาณได้ครอบคลุมมากยิ่งขึ้น และช่วยเพิ่มศักยภาพในการประยุกต์ใช้กับข้อมูลที่ไม่เคยพบมาก่อนได้





รูปที่ 2 ตัวอย่างข้อมูล B-scan จาก 4 แหล่งหลัก ได้แก่ (ก) กรุงเทพมหานคร (ข) ประเทศญี่ปุ่น (ค) RoboFlow Universe และ (ง) gprMax

จำนวนภาพทั้งหมดที่ใช้ในการทดลองมี 1,391 ภาพ โดยประกอบด้วย ทั้งภาพที่ปรากฏโพรงและภาพที่ไม่พบโพรง ซึ่งภาพที่ไม่พบโพรงจัดให้อยู่ในกลุ่ม Background เพื่อช่วยให้แบบจำลองเรียนรู้ลักษณะของสัญญาณที่ไม่ใช่โพรง และลดโอกาสการตรวจจับผิดพลาด (false positive) ในบริเวณที่มีรูปแบบสัญญาณคล้ายโพรงแต่ไม่ใช่เป้าหมายจริง

ก่อนการแบ่งชุดข้อมูลสำหรับการฝึกและประเมินผล ได้กำหนดสัดส่วนของข้อมูลจากแต่ละแหล่ง โดยใช้ข้อมูลภาคสนามจากกรุงเทพมหานครเป็นข้อมูลหลักร้อยละ 70 ขณะที่ข้อมูลภาคสนามจากประเทศญี่ปุ่นกับข้อมูลจาก RoboFlow Universe และข้อมูลสังเคราะห์จาก gprMax ถูกใช้รวมกันในสัดส่วนร้อยละ 30 จากรูปทั้งหมด เพื่อเพิ่มความหลากหลายของรูปแบบสัญญาณ และช่วยให้แบบจำลองเรียนรู้ลักษณะของโพรงได้ครอบคลุมมากยิ่งขึ้น

2.1.1 การสร้างแบบจำลองด้วย gprMax

ในการสร้างข้อมูลสังเคราะห์ด้วย gprMax [15] งานวิจัยนี้ได้กำหนดพารามิเตอร์บางส่วนให้คงที่ เพื่อควบคุมสภาพแวดล้อมพื้นฐานของการจำลองให้มีความสม่ำเสมอ และลดผลกระทบจากปัจจัยที่ไม่เกี่ยวข้องต่อรูปแบบสัญญาณสะท้อน เช่น ความหนาของชั้นผิวทาง ขนาดโดเมน ระยะก้าวการสแกน และช่วงเวลาที่ใช้บันทึกสัญญาณ โดยพารามิเตอร์เหล่านี้ไม่ถูกกำหนดให้เปลี่ยนแปลงแบบสุ่ม เนื่องจากเป็นค่าพื้นฐานที่ใช้ควบคุมเงื่อนไขของการจำลองให้คงที่ตลอดการทดลอง เพื่อให้ความแตกต่างของข้อมูลที่ได้สะท้อนผลจากลักษณะของวัตถุและสมบัติของวัสดุเป็นหลัก

ขณะที่พารามิเตอร์บางส่วนถูกกำหนดให้เปลี่ยนแปลงแบบสุ่มภายในช่วงที่กำหนด เพื่อเพิ่มความหลากหลายของข้อมูลสังเคราะห์และทำให้แบบจำลองสามารถเรียนรู้ลักษณะของโพรงภายใต้เงื่อนไขที่แตกต่างกันได้ดีขึ้น โดยพารามิเตอร์ที่สุ่ม ได้แก่ ความถี่ คุณสมบัติทางไฟฟ้าของดิน ขนาดโพรง ความลึก ตำแหน่งในแนวนอน และชนิดของวัตถุ ซึ่งเป็นปัจจัยที่มีผลโดยตรงต่อลักษณะการสะท้อนของสัญญาณ GPR และรูปแบบของโพรงที่ปรากฏในข้อมูล B-scan ดังนั้น การกำหนดพารามิเตอร์ในลักษณะดังกล่าวจึงช่วยให้ข้อมูลสังเคราะห์ที่สร้างขึ้นมีความหลากหลาย และเหมาะสมสำหรับนำไปใช้ในการฝึกและทดสอบแบบจำลองตรวจจับโพรงใต้ผิวทาง

นอกจากนี้ การสุ่มพารามิเตอร์ยังช่วยลดข้อจำกัดของข้อมูลที่มีรูปแบบเฉพาะมากเกินไป ซึ่งอาจทำให้แบบจำลองเรียนรู้เฉพาะลักษณะของข้อมูลบางชุดเท่านั้น อีกทั้งยังช่วยให้แบบจำลองสามารถปรับตัวต่อความแปรผันของสภาพพื้นดินได้ดีขึ้น และทำให้ข้อมูลสังเคราะห์มีความหลากหลายรวมทั้งใกล้เคียงกับสภาพจริงมากยิ่งขึ้น


ตารางที่ 1 พารามิเตอร์ที่ของแบบจำลอง gprMax

Parameter	Value
-----------	-------

Asphalt thickness	0.10 m [16]
Concrete thickness	0.2 m [17]
Soil base	ชั้นดินฐานของแบบจำลอง
Domain y	1.5 m
dx	0.01 m
Time window	20 ns
N traces	150
Trace step	0.05 m
Antenna separation	0.1 m

ตารางที่ 2 พารามิเตอร์แบบสุ่มของแบบจำลอง gprMax

Parameter	Range
Frequency	200, 300, 500 MHz [17]
Soil relative permittivity	5-15 [18]
Soil electrical conductivity	0.001-0.02 S/m [18]
Radius	0.05-0.2 m
Depth	0.2-1.2 m
Time window	สุ่มตามช่วงที่กำหนด
X-position	สุ่มตามตำแหน่งแนวนอน
Object type	Air-void, metal, none




รูปที่ 3 ตัวอย่างภาพข้อมูลจาก gprMax สำหรับกรณี (ก) โพรงอากาศ (ข) วัตถุโลหะ และ (ค) ไม่มีวัตถุ

จากนั้นข้อมูลทั้งหมดจะถูกแบ่งออกเป็นชุดข้อมูลสำหรับฝึกสอนแบบจำลอง (Training set) ชุดตรวจสอบความถูกต้องระหว่างการฝึก (Validation set) และชุดทดสอบสมรรถนะของแบบจำลอง (Test set) ในอัตราส่วน 80:10:10 ตามลำดับ

2.2 การเตรียมข้อมูลและการระบุตำแหน่งของโพรง

2.2.1 เกณฑ์การพิจารณาคำแหน่งโพรงสำหรับภาคสนาม


ในการศึกษานี้ การพิจารณาดำแหน่งโครงจากรูปที่ 4 ใช้ภาพ GPR แบบ B-scan เป็นหลัก โดยตรวจสอบลักษณะสัญญาณไฮเพอร์โบลา และใช้ข้อมูล A-scan กับ C-scan ร่วมยืนยันความสอดคล้องของตำแหน่ง หากข้อมูลทั้งสามส่วนสนับสนุนตรงกัน จึงพิจารณาว่าตำแหน่งนั้นเป็นโครง แนวทางนี้ช่วยเพิ่มความน่าเชื่อถือของการแปลผล ลดความคลาดเคลื่อนจากการพิจารณาภาพ B-scan เพียงอย่างเดียว และทำให้การระบุตำแหน่งโครงมีความแม่นยำและสอดคล้องกับสภาพข้อมูลจริงมากขึ้น



รูปที่ 4 การพิจารณาดำแหน่งโครงจากข้อมูล B-scan

2.3 การระบุตำแหน่งโครง

เมื่อจัดเตรียมข้อมูล GPR แบบ B-scan จากข้อมูลภาคสนามและข้อมูลสังเคราะห์เรียบร้อยแล้ว ผู้วิจัยได้คัดเลือกภาพที่มีลักษณะเป็นโครง เพื่อสร้างชุดข้อมูลสำหรับการตรวจจับวัตถุ จากนั้นจึงระบุตำแหน่งโครงในภาพด้วยกรอบสี่เหลี่ยมล้อมรอบบริเวณที่เป็นสัญญาณสำคัญ ตามรูปที่ 5 สำหรับการฝึกแบบจำลอง โดยใช้โปรแกรม RoboFlow ในการจัดการและแปลงชุดข้อมูลให้อยู่ในรูปแบบที่เหมาะสมกับแบบจำลองในตระกูล YOLO ในการกำหนดกรอบตำแหน่งวัตถุ ผู้วิจัยพิจารณาให้ครอบคลุมบริเวณสัญญาณที่แสดงลักษณะเด่นของโครงในภาพ B-scan โดยเฉพาะส่วนโค้งของสัญญาณสะท้อนที่มีรูปแบบใกล้เคียงไฮเพอร์โบลา เพื่อให้แบบจำลองสามารถเรียนรู้ตำแหน่งและขอบเขตของวัตถุเป้าหมายได้อย่างเหมาะสม หลังจากนั้นข้อมูลทั้งหมดจะถูกแบ่งออกเป็นชุดข้อมูลสำหรับฝึกสอนแบบจำลอง (Training set) ชุดตรวจสอบความถูกต้องระหว่างการฝึก (Validation set) และชุดทดสอบสมรรถนะของแบบจำลอง (Test set) ในอัตราส่วน 80:10:10 ตามลำดับ




รูปที่ 5 การระบุตำแหน่งโครงในโปรแกรม RoboFlow

2.4 แบบจำลองที่ใช้ในการศึกษา

2.4.1 สถาปัตยกรรมของแบบจำลองตรวจจับวัตถุ

แบบจำลองตรวจจับวัตถุในตระกูล YOLO [20] เป็นแบบจำลองชนิดขั้นตอนเดียว (One-stage detector) ที่สามารถระบุตำแหน่งและจำแนกประเภทของวัตถุได้ภายในกระบวนการเดียว จึงมีจุดเด่นด้านความเร็วและประสิทธิภาพในการประมวลผล สถาปัตยกรรมโดยทั่วไปประกอบด้วย 3 ส่วนสำคัญ ตามรูปที่ 6 ได้แก่ Backbone, Neck และ Head โดย Backbone ทำหน้าที่สกัดคุณลักษณะจากภาพนำเข้า Neck ทำหน้าที่ผสมผสานคุณลักษณะจากหลายระดับความละเอียดเพื่อรองรับการตรวจจับวัตถุหลายขนาด และ Head ทำหน้าที่ทำนายตำแหน่งกรอบล้อมวัตถุ ค่าความเชื่อมั่น และประเภทของวัตถุที่ตรวจพบ

ในงานวิจัยนี้ยังมีการนำ DINO มาใช้ร่วมกับแบบจำลองตรวจจับวัตถุ เพื่อเพิ่มประสิทธิภาพในการเรียนรู้คุณลักษณะของภาพ โดย DINO เป็นแนวทางการเรียนรู้แบบ Self-supervised บน Vision Transformer ที่ช่วยให้แบบจำลองสามารถสกัดลักษณะสำคัญของข้อมูลได้ดีขึ้น [21] ซึ่งช่วยให้แยกแยะโครงได้ชัดเจนขึ้น



รูปที่ 6 โครงสร้างการทำงานของแบบจำลองตรวจจับวัตถุ

2.4.2 แบบจำลองที่ใช้ในการทดลอง

งานวิจัยนี้ใช้แบบจำลองตรวจจับวัตถุ 4 กลุ่ม ได้แก่ YOLOv12, YOLOv26, YOLOv12-DINOv3 และ YOLOv13-DINOv3 สำหรับตรวจจับโครงจากข้อมูล GPR แบบ B-scan โดย YOLOv12 และ YOLOv26 ใช้เป็นแบบจำลองพื้นฐานเพื่อเปรียบเทียบสมรรถนะของสถาปัตยกรรมในตระกูล YOLO ขณะที่แบบจำลองผสมถูกนำมาใช้เพื่อศึกษาศักยภาพของการผสานการตรวจจับวัตถุกับการเรียนรู้คุณลักษณะเชิงลึกของภาพ ทั้งนี้ การเลือกใช้แบบจำลองทั้ง 4 กลุ่มมีวัตถุประสงค์เพื่อเปรียบเทียบประสิทธิภาพด้านความแม่นยำ ความสามารถในการตรวจจับตำแหน่งโครง และเหมาะสมต่อการประยุกต์ใช้กับข้อมูล GPR แบบ B-scan

2.5 เกณฑ์การประเมินผล

งานวิจัยนี้ประเมินผลของแบบจำลองด้วยตัวชี้วัดมาตรฐานของงานตรวจจับวัตถุ ได้แก่ Recall, Precision, F1-score และ Mean Average Precision (mAP) เพื่อสะท้อนความสามารถของแบบจำลองในการตรวจจับโครงจากข้อมูล GPR แบบสองมิติในรูปแบบ B-scan [22]

ค่า Recall ใช้แสดงความสามารถของแบบจำลองในการตรวจพบโครงจริงทั้งหมดในชุดข้อมูลทดสอบ ดังสมการที่ (1) ขณะที่ค่า Precision ใช้แสดงความแม่นยำของผลการตรวจจับ ดังสมการที่ (2)

$$Recall = \frac{TP}{TP + FN} \quad (1)$$

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

โดยที่ผลบวกจริง (True Positive; TP) คือจำนวนโครงที่แบบจำลองตรวจพบได้ถูกต้อง ซึ่งพิจารณาจากการเปรียบเทียบกรอบทำนาย (Predicted bounding box) กับกรอบอ้างอิงจริง (Ground truth bounding box) หากกรอบทั้งสองมีตำแหน่งซ้อนทับกันตามค่าเกณฑ์ Intersection over Union (IoU) ที่กำหนด และเป็นตำแหน่งโครงเดียวกันจะนับเป็นการตรวจจับที่ถูกต้อง ส่วนผลบวกเท็จ (False Positive; FP) คือกรณีที่แบบจำลองทำนายว่าเป็นโครง แต่ไม่ตรงกับตำแหน่งโครงจริงหรือไม่ มีโครงจริงในบริเวณนั้น และผลลบเท็จ (False Negative; FN) คือกรณีที่มีโครงจริงอยู่ในข้อมูลอ้างอิง แต่แบบจำลองตรวจไม่พบ ทั้งนี้ ค่า FN มีความสำคัญต่อการใช้งานภาคสนาม เนื่องจากอาจทำให้พื้นที่เสี่ยงถูกมองข้าม จึงควรพิจารณาค่าการตรวจพบโครงจริง (Recall) และจำนวน FN ร่วมด้วยในการประเมินแบบจำลอง

F1-score ใช้สรุปสมรรถนะระหว่าง Precision และ Recall ในรูปของค่าเฉลี่ยฮาร์โมนิก ดังสมการที่ (3) ซึ่งเหมาะสำหรับใช้ประเมินแบบจำลองในกรณีที่ต้องการพิจารณาทั้งความแม่นยำและความครอบคลุมของการตรวจจับร่วมกัน [22]

$$F1\text{-score} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3)$$

นอกจากนี้ งานวิจัยนี้ยังใช้ค่า mAP เป็นตัวชี้วัดสมรรถนะโดยรวมของแบบจำลองตรวจจับวัตถุ โดยคำนวณจากค่าเฉลี่ยของ AP ของแต่ละคลาส ดังสมการที่ (4) ตามแนวทางการประเมินแบบ COCO โดย k คือจำนวนคลาสที่ใช้ในการประเมินผล ค่าดังกล่าวสะท้อนความสามารถของแบบจำลองในการตรวจจับวัตถุได้อย่างถูกต้องทั้งในด้านตำแหน่งและการ

จำแนกประเภท อีกทั้งยังช่วยให้สามารถเปรียบเทียบสมรรถนะของแบบจำลองแต่ละแบบได้อย่างเป็นมาตรฐานและชัดเจนมากยิ่งขึ้น [23]

$$mAP = \frac{\sum_{i=1}^k AP_i}{k} \quad (4)$$

3. ผลการวิเคราะห์และอภิปรายผล

เพื่อคัดเลือกแบบจำลองที่เหมาะสมสำหรับการตรวจจับโครงใต้ผิวทางจากข้อมูล GPR การศึกษานี้เปรียบเทียบผลการทดลองของแบบจำลองออกเป็น 3 กลุ่ม ดังแสดงในตารางที่ 3-5 ได้แก่ แบบจำลองที่เทรนจากพารามิเตอร์เริ่มต้นแบบสุ่ม แบบจำลองที่ใช้ Pretrained weights จาก COCO และแบบจำลองที่ผสาน DINOv3 โดยพิจารณาจากค่า Precision, Recall, F1-score และ mAP@0.5 ร่วมกัน เพื่อเลือกแบบจำลองที่มีศักยภาพสูงที่สุดในแต่ละกลุ่ม

สำหรับแบบจำลองที่เทรนจากพารามิเตอร์เริ่มต้นแบบสุ่ม แบบจำลองที่แนะนำจากตารางที่ 3 คือ YOLOv12m เนื่องจากให้ค่า mAP@0.5 สูงที่สุดในกลุ่มนี้เท่ากับ 0.530 และมีค่า Recall สูงที่สุดเท่ากับ 0.521 แสดงให้เห็นว่า YOLOv12m มีความสามารถในการตรวจพบโครงจริงได้ดีกว่าแบบจำลองอื่นในกลุ่มเดียวกัน จึงเหมาะสำหรับใช้เป็นแบบจำลองพื้นฐานในกรณีที่ไม่ได้ใช้ Pretrained weights

จากตารางที่ 4 สำหรับแบบจำลองที่ใช้ Pretrained weights จาก COCO แบบจำลองที่แนะนำมากที่สุดคือ YOLOv26s เนื่องจากให้ค่า Precision สูงที่สุดเท่ากับ 0.820 และค่า mAP@0.5 สูงที่สุดเท่ากับ 0.581 เมื่อเทียบกับแบบจำลองทั้งหมดในการศึกษานี้ ผลดังกล่าวสะท้อนว่า YOLOv26s สามารถตรวจจับตำแหน่งโครงได้อย่างแม่นยำในระดับดี และมีประสิทธิภาพโดยรวมโดดเด่นที่สุด จึงเหมาะสำหรับใช้เป็น baseline หลักของงานวิจัยนี้ รวมถึงเป็นจุดอ้างอิงสำหรับการพัฒนาแบบจำลองตรวจจับโครงใต้ผิวทางจากข้อมูล GPR ในอนาคต สำหรับแบบจำลองที่ผสาน DINOv3 จากตารางที่ 5 แบบจำลองที่แนะนำในกลุ่มนี้คือ

YOLOv12m-DINOv3 เนื่องจากให้ค่า mAP@0.5 สูงที่สุดเท่ากับ 0.537 แสดงให้เห็นว่าการผสาน DINOv3 สามารถช่วยเพิ่มศักยภาพของแบบจำลองในบางกรณีได้ นอกจากนี้ YOLOv13L-DINO-Unfreeze ยังให้ค่า Recall และ F1-score สูงที่สุดในกลุ่มนี้ เท่ากับ 0.472 และ 0.554 ตามลำดับ จึงเป็นอีกแบบจำลองที่น่าสนใจสำหรับการพัฒนาต่อ โดยเฉพาะในด้านการเพิ่มความสามารถในการตรวจพบโครงจริง

ตารางที่ 3 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลองที่เทรนจากพารามิเตอร์เริ่มต้นแบบสุ่ม

Model	Precision	Recall	F1-Score	mAP
YOLOv12n	0.676	0.368	0.477	0.519
YOLOv12s	0.696	0.401	0.509	0.517
YOLOv12m	0.611	0.521	0.562	0.530
YOLOv12l	0.725	0.423	0.534	0.523
YOLOv26n	0.561	0.424	0.483	0.478
YOLOv26s	0.551	0.479	0.512	0.492
YOLOv26m	0.595	0.479	0.531	0.520
YOLOv26l	0.690	0.377	0.488	0.493


ตารางที่ 4 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลองที่ใช้ Pretrained weights จาก COCO

Model	Precision	Recall	F1-Score	mAP
YOLOV12n	0.645	0.437	0.521	0.553
YOLOV12s	0.644	0.437	0.521	0.560
YOLOV12m	0.657	0.433	0.522	0.551
YOLOV12l	0.611	0.465	0.528	0.526
YOLOV26n	0.690	0.439	0.537	0.550
YOLOV26s	0.820	0.466	0.594	0.581
YOLOV26m	0.797	0.408	0.540	0.558
YOLOV26l	0.725	0.437	0.545	0.527


ตารางที่ 5 ผลการเปรียบเทียบแบบจำลอง YOLO-DINOv3

Model	Precision	Recall	F1-Score	mAP
YOLOV12n-DINOv3	0.633	0.423	0.507	0.529
YOLOV12m-DINOv3	0.735	0.380	0.501	0.537
YOLOV12l-DINOv3	0.656	0.444	0.530	0.534
YOLOV13l-DINO-F	0.613	0.450	0.519	0.500
YOLOV13l-DINO-UF	0.670	0.472	0.554	0.528

โดยสรุป YOLOv26s ที่ใช้ Pretrained weights จาก COCO เป็นแบบจำลองที่เหมาะสมที่สุดสำหรับใช้เป็น baseline หลักของงานวิจัยนี้ เนื่องจากให้ค่า mAP@0.5 สูงที่สุดในการทดลอง ขณะที่แบบจำลองกลุ่มอื่นยังมีจุดเด่นเฉพาะด้าน แต่ยังไม่ให้ผลเหนือกว่า YOLOv26s อย่างชัดเจน นอกจากนี้ เวลาในการประมวลผลยังเป็นอีกปัจจัยสำคัญต่อการนำแบบจำลองไปประยุกต์ใช้ในงานภาคสนาม



รูปที่ 7 ความสัมพันธ์ระหว่าง mAP50 กับเวลาในการประมวลผลของแบบจำลองตำแหน่งและขนาด Bounding box อยู่บ้าง โดยเฉพาะเมื่อสัญญาณไม่



รูปที่ 8 ความสัมพันธ์ระหว่างค่า mAP50 และ FLOPs

นอกจากนี้ การผสานแบบจำลองยังทำให้โครงสร้างมีความซับซ้อนมากขึ้นซึ่งทำให้ข้อได้เปรียบของการสกัดคุณลักษณะเชิงลึกยังไม่แสดงออกอย่างเด่นชัดในงานวิจัยนี้ เมื่อพิจารณาาร่วมกับกราฟความสัมพันธ์ระหว่างค่า mAP@0.5 และ latency ในรูปที่ 7 จะเห็นว่าแบบจำลองที่ใช้ pretrained โดยเฉพาะในตระกูล YOLOv26 มีความสมดุลระหว่างความแม่นยำและเวลาในการประมวลผลได้ดีกว่าแบบจำลองกลุ่มอื่น โดยเฉพาะ YOLOv26s ซึ่งเป็นแบบจำลองที่มีความเหมาะสมที่สุดสำหรับการตรวจจับโพรงใต้ผิวทางจากข้อมูล GPR แบบสองมิติในรูปแบบ B-scan ทั้งนี้ ผลการทดลองยังสะท้อนให้เห็นว่าการเพิ่มความซับซ้อนของแบบจำลองไม่ได้ทำให้ประสิทธิภาพโดยรวมดีขึ้นอย่างชัดเจนเสมอไป

การทดลองในงานวิจัยนี้ใช้หน่วยประมวลผลกราฟิกแตกต่างกันได้แก่ NVIDIA GeForce RTX 4060 Ti (15401 MiB ≈ 15 GB), NVIDIA GeForce RTX 5060 Ti (15484 MiB ≈ 15 GB), NVIDIA RTX A6000 (48541 MiB ≈ 48 GB), NVIDIA RTX A5000 (24112 MiB ≈ 24 GB) และ NVIDIA RTX PRO 4000 Blackwell (23980 MiB ≈ 24 GB)

เมื่อพิจารณากราฟความสัมพันธ์ระหว่างค่า mAP@0.5 และ FLOPs ในรูปที่ 8 พบว่า YOLOv26 ที่ใช้ pretrained weights ให้ความแม่นยำสูงและใช้ FLOPs ในระดับเหมาะสม จึงมีความคุ้มค่าเชิงประสิทธิภาพดีกว่าแบบจำลองอื่น ขณะที่ YOLOv12 ที่ใช้ pretrained ให้ผลใกล้เคียงกันในบางขนาด แต่โดยรวมยังน้อยกว่าเล็กน้อย ส่วนแบบจำลองที่ผสานแม้ยังคงความแม่นยำได้ในระดับหนึ่ง แต่ต้องใช้เวลาประมวลผลสูงกว่าแบบจำลองอื่น

จากผลการประเมินเชิงคุณภาพในตารางที่ 6-8 พบว่าแบบจำลองสามารถตรวจจับตำแหน่งของโพรงจากข้อมูล GPR แบบ B-scan ได้ดีในกรณีที่สัญญาณมีลักษณะเป็น hyperbola ค่อนข้างชัดเจน โดยผลการตรวจจับของ YOLOv26s ที่ใช้ Pretrained weights มีความสอดคล้องกับ Ground Truth มากกว่า และให้ค่า Confidence สูงกว่าเมื่อเทียบกับแบบจำลองอื่น สะท้อนถึงความเชื่อมั่นในการตัดสินใจที่ดีกว่า ขณะที่ YOLOv12m แบบ Random initialization และ YOLOv12m-DINOv3 แม้ยังสามารถตรวจจับโพรงได้ในบางกรณี แต่พบความคลาดเคลื่อนของตำแหน่งหรือมีสัญญาณรบกวนสูง ซึ่งส่งผลให้ค่า Confidence ลดลงและแสดงถึงความไม่แน่นอนของแบบจำลองมากขึ้น ผลดังกล่าวชี้ให้เห็นว่า







ความชัดเจนของลักษณะสัญญาณและความใกล้เคียงระหว่างข้อมูลฝึกกับข้อมูลทดสอบมีผลต่อประสิทธิภาพการตรวจจับอย่างสำคัญ

4. อภิปรายผล

ผลการทดลองแสดงให้เห็นว่าแบบจำลองที่ใช้ Pretrained weights จากชุดข้อมูล COCO มีประสิทธิภาพสูงกว่าการเทรนจาก random initialization อย่างชัดเจน เนื่องจาก pretrained weights ช่วยให้แบบจำลองมีพื้นฐานในการเรียนรู้คุณลักษณะของภาพ เช่น ขอบ รูปร่าง และรูปแบบของสัญญาณตั้งแต่ช่วงเริ่มต้น แม้ข้อมูล COCO จะแตกต่างจากข้อมูล GPR แต่คุณลักษณะพื้นฐานระดับต่ำ (Low-level features) ยังสามารถนำมาปรับใช้กับการตรวจจับรูปแบบไฮเพอร์โบลาในภาพ B-scan ได้บางส่วน ส่งผลให้แบบจำลองตรวจจับโพรงได้ดีกว่าแบบจำลองที่เทรนจาก random initialization อย่างไรก็ตาม ความแตกต่างของโดเมนระหว่างภาพ RGB ทั่วไปกับข้อมูล GPR ยังเป็นข้อจำกัดที่ต้องพิจารณา โดยเฉพาะในด้านสัญญาณรบกวน ความเข้มของการสะท้อน และความไม่ชัดเจนของขอบเขตโพรง







4.1 ตัวอย่างผลการตรวจจับแบบจำลอง

ตารางที่ 6 ผลลัพธ์การตรวจจับโพรง (Random Initialization)







Case	Ground Truth	Best model (random.)	
		YOLOv12m	
1			
2			
3			

ตารางที่ 7 ผลลัพธ์การตรวจจับโพรง (Pretrained weights)

Case	Ground Truth	Best model (Pretrained)	
		YOLOv26s	

1			
2			
3			

ตารางที่ 8 ผลลัพธ์การตรวจจับโพรงของ YOLO-DINO

Case	Ground Truth	Best model	
		YOLOv12m-DINOv3	
1			
2			
3			

YOLOv26s ที่ใช้ Pretrained ให้ค่า $mAP@0.5 = 0.581$ ซึ่งสูงกว่า YOLOv12m ที่เทรนจาก Random Initialization ($mAP@0.5 = 0.530$) ถึง 9.4% แบบสัมพัทธ์ ผลดังกล่าวสอดคล้องกับหลักการของ domain adaptation ในงาน transfer learning ที่ Pretrained weights ช่วยให้ backbone สามารถสกัดคุณลักษณะระดับต่ำ (low-level features) เช่น

ขอบ รูปทรง และพื้นผิว ได้อย่างมีประสิทธิภาพตั้งแต่ต้น แม้ว่าโดเมนของ COCO จะแตกต่างจากข้อมูล GPR อย่างมาก อย่างไรก็ตาม เนื่องจากภาพ B-scan ของ GPR มีโครงสร้างสัญญาณที่เป็น hyperbolic signature ซึ่งมีลักษณะทางเรขาคณิตที่แน่นอน จึงเป็นไปได้ว่า filter ระดับต้นที่ pretrained มาแล้วสามารถนำมาใช้ซ้ำในการตรวจจับรูปทรง hyperbola ได้บางส่วน

เมื่อพิจารณาในสภาวะที่ใช้ Pretrained weights เปรียบเทียบกัน พบว่า YOLOv26 ให้ค่า precision สูงกว่า YOLOv12 อย่างชัดเจน โดย YOLOv26s ให้ค่า Precision = 0.820 เทียบกับ YOLOv12s ที่ Precision = 0.644 ซึ่งสะท้อนว่าสถาปัตยกรรมของ YOLOv26 มีความสามารถในการลด false positive ได้ดีกว่า อย่างไรก็ตาม ค่า Recall ของทุกแบบจำลองยังอยู่ในช่วง 0.40–0.47 อันบ่งชี้ว่าแบบจำลองยังตรวจพลาดโพรงจริงจำนวนหนึ่ง (false negative) ซึ่งเป็นความท้าทายสำคัญในบริบทของการตรวจสอบโครงสร้างพื้นฐาน เนื่องจาก False negative มีนัยสำคัญต่อความปลอดภัยสาธารณะมากกว่า False positive ความไม่สมมาตรดังกล่าว ระหว่าง Precision และ Recall ใน YOLOv26s (0.820 vs. 0.466) ชี้ให้เห็นว่าการปรับ Confidence threshold ให้ต่ำอาจช่วยเพิ่ม Recall ได้ในงานประยุกต์ใช้จริง โดยยอมรับ False positive เพิ่มขึ้นบ้างเพื่อแลก กับความครอบคลุมของการตรวจจับ

สำหรับแบบจำลองผสม YOLO-DINOv3 ให้ผลการตรวจจับอยู่ในช่วงกลาง คือ mAP@0.5 ระหว่าง 0.500–0.537 โดยสูงกว่าการเทรนจาก Random Initialization เล็กน้อย แต่ต่ำกว่า YOLOv26s ที่ใช้ Pretrained weights ผลนี้สามารถอธิบายได้จากสาเหตุหลักสองประการ ประการแรก DINOv3 ถูก Pretrained มาจากข้อมูลภาพ RGB ทั่วไปโดยใช้ Self-supervised learning บน Vision Transformer ซึ่งทำให้ representation ที่ได้ไม่ได้ออก optimize สำหรับลักษณะเฉพาะของสัญญาณ GPR เช่น ความแตกต่างของ dielectric contrast หรือรูปแบบ hyperbolic reflection

ประการที่สอง คือการผสมสถาปัตยกรรมของตัว YOLO ซึ่งเป็น convolutional one-stage detector ผสมเข้ากับ Vision Transformer backbone ของ DINOv3 ก่อให้เกิดความซับซ้อนในการ feature fusion ระหว่าง local convolutional features และ Global attention-based representations ทำให้ประโยชน์ของ DINOv3 อาจถูกจำกัดโดยคอขวดทางสถาปัตยกรรมนี้ นอกจากนี้ เมื่อพิจารณาเปรียบเทียบระหว่าง YOLOv13l-DINO-Freeze (mAP = 0.5) กับ YOLOv13l-DINO-Unfreeze (mAP = 0.528) พบว่าการ Fine-tune weights ของ DINOv3 ร่วมกันให้ผลดีกว่าการ freeze ซึ่งสนับสนุนข้อสรุปว่า DINOv3 ต้องการการ Adaptation เพิ่มเติมจากข้อมูล GPR จึงจะแสดงศักยภาพได้เต็มที่

การออกแบบชุดข้อมูลในงานวิจัยนี้ที่ผสมข้อมูลจาก 4 แหล่งหลักเป็นกลยุทธ์ที่มีเหตุผลทางทฤษฎีที่ชัดเจน เนื่องจากข้อมูล GPR ภาคสนามจากกรุงเทพมหานครที่เป็นชั้นดินเหนียวอ่อนมากถึงดินเหนียวอ่อนมีค่า Relative permittivity และพฤติกรรมสัญญาณที่แตกต่างจากข้อมูลภาคสนามจากประเทศญี่ปุ่นและข้อมูลสังเคราะห์จาก gprMax รวมไปถึงข้อมูลจาก Roboflow Universe อย่างมีนัยสำคัญ ทั้งนี้การจัดสรรสัดส่วนข้อมูลที่กรุงเทพมหานคร 70% สะท้อนถึงเจตนาในการ prioritize domain-specific learning ขณะที่ 30% ที่เหลือช่วยป้องกัน overfitting ต่อรูปแบบสัญญาณเฉพาะของชั้นดินในกรุงเทพฯ อย่างไรก็ตาม ค่า mAP@0.5 สูงสุดที่ 0.581 ยังถือว่าอยู่ในระดับปานกลาง บ่งชี้ว่าการแปรปรวนของสัญญาณ GPR ที่เกิดจากความหลากหลายของสภาพชั้นดิน ระดับน้ำใต้ดิน

และความลึกของโพรงในสภาพแวดล้อมเมืองกรุงเทพฯ ยังเป็นอุปสรรคสำคัญที่จำกัดสมรรถนะของแบบจำลอง

เมื่อพิจารณาความสัมพันธ์ระหว่าง mAP@0.5, Latency และ FLOPs พบว่า YOLOv26s ให้สมดุลด้านประสิทธิภาพดีที่สุดในกลุ่มแบบจำลองที่ทดสอบ โดยให้ค่า mAP@0.5 สูงสุด ขณะที่ใช้ FLOPs อยู่ในระดับกลาง ส่วนแบบจำลองผสม DINO-YOLO แม้ให้ค่า mAP@0.5 ใกล้เคียงกับ YOLOv12 pretrained แต่มีต้นทุนด้าน Latency และ FLOPs สูงกว่าอย่างชัดเจน จึงมีความคุ้มค่าต่ำกว่าในการประยุกต์ใช้จริง

5. สรุปผลการศึกษาและแนวทางการศึกษาเพิ่มเติม

5.1 สรุปผลการศึกษา

งานวิจัยนี้ศึกษาการตรวจจับโพรงใต้ผิวทางจากข้อมูล GPR แบบสองมิติในรูปแบบ B-scan โดยเปรียบเทียบแบบจำลองในตระกูล YOLOv12 และ YOLOv26 ทั้งในสภาวะการเทรนจาก random initialization และการใช้ Pretrained weights จาก COCO รวมถึงแบบจำลองผสมที่บูรณาการ DINOv3 เข้ากับสถาปัตยกรรม YOLO โดยใช้ชุดข้อมูลที่ประกอบด้วยข้อมูลภาคสนามจากกรุงเทพมหานครเป็นหลัก ร่วมกับข้อมูลจากประเทศญี่ปุ่น Roboflow Universe และข้อมูลสังเคราะห์จาก gprMax ผลการศึกษาสามารถสรุปได้ดังนี้

ภายใต้การเทรนจากค่าเริ่มต้นแบบสุ่ม พบว่า YOLOv12m ให้ผลดีที่สุดในกลุ่มนี้ด้วยค่า mAP@0.5 = 0.530 แสดงให้เห็นว่าสามารถเรียนรู้ลักษณะสัญญาณโพรงจากข้อมูล GPR ได้ ขณะที่กลุ่ม pretrained weights แบบจำลองตระกูล YOLOv26 ให้ผลดีขึ้นอย่างชัดเจน โดย YOLOv26s ให้ค่า mAP@0.5 สูงสุดที่ 0.581 พร้อม Precision = 0.820 และ F1-score = 0.594 ซึ่งเป็นค่าสูงสุดของการศึกษา อย่างไรก็ตาม ค่า Recall = 0.466 แสดงว่าแบบจำลองยังตรวจพบโพรงจริงได้ไม่ครอบคลุม จึงเป็นข้อจำกัดสำคัญต่อการนำไปใช้จริง

สำหรับแบบจำลองผสม YOLO-DINOv3 แม้การ Fine-tune แบบ Unfreeze มีผลดีกว่าแบบ Freeze (mAP@0.5 = 0.528 เทียบกับ 0.500) แต่สมรรถนะโดยรวมยังต่ำกว่า YOLOv26s Pretrained สาเหตุอาจมาจากความแตกต่างของโดเมนระหว่างภาพ RGB ที่ใช้ฝึก DINOv3 กับสัญญาณ GPR รวมถึงค่า FLOPs และ latency ที่สูงกว่า ทำให้ยังไม่คุ้มค่าเมื่อเทียบกับ YOLOv26s Pretrained ดังนั้น YOLOv26s Pretrained จึงเหมาะสมที่สุดสำหรับใช้เป็น baseline หลักในการศึกษานี้

5.2 ข้อจำกัดและข้อควรระวังในการนำไปใช้จริง

งานวิจัยนี้มีข้อจำกัดหลายประการ ได้แก่ การใช้ข้อมูลของ GPR แบบ B-scan สองมิติเท่านั้น ซึ่งอาจยังไม่ครอบคลุมบริบทเชิงพื้นที่ของข้อมูล GPR แบบ 3D และ DINOv3 ที่ยังไม่ได้รับการ pretrain จากโดเมน GPR โดยตรง

ค่า Recall เท่ากับ 0.466 แสดงว่าแบบจำลองตรวจพบโพรงจริงได้ประมาณร้อยละ 46.6 จึงยังตรวจพบโพรงจริงได้ไม่ครบถ้วน และอาจเกิด False negative คือกรณีที่มีโพรงจริงแต่แบบจำลองตรวจไม่พบ ซึ่งทำให้ตำแหน่งโพรงหรือพื้นที่เสี่ยงบางส่วนถูกมองข้ามได้ ดังนั้น ค่า Recall ที่ยังไม่สูงมากจึงถือเป็นข้อจำกัดของงานวิจัยนี้ โดยผลลัพธ์จาก YOLOv26s ควรใช้เป็นเครื่องมือช่วยคัดกรองพื้นที่เสี่ยงและกำหนดแนวทางการสำรวจเบื้องต้น ก่อนนำผลไปตรวจสอบและยืนยันในภาคสนามจริงโดยผู้เชี่ยวชาญ นอกจากนี้ การศึกษาครั้งนี้มีจำนวนรูปเพียง 1,391 ภาพ ดังนั้นในอนาคต

ควรเพิ่มจำนวนภาพ GPR ภาคสนาม เพื่อช่วยลดการตรวจพลาดและเพิ่มค่า Recall ได้ในอนาคต

สำหรับการนำแบบจำลองไปใช้งานจริง โดยการศึกษาครั้งนี้กำหนดค่า Confidence threshold เท่ากับ 0.4 ในการประเมินผลแบบจำลอง อย่างไรก็ตาม ค่าดังกล่าวอาจไม่เหมาะสมกับทุกกรณีการใช้งานจริง จึงควรพิจารณาปรับค่า threshold ให้สอดคล้องกับระดับความเสี่ยงและวัตถุประสงค์ของงานสำรวจ เนื่องจากการลดค่า Threshold อาจช่วยลดโอกาสการตรวจพลาด แต่ในขณะเดียวกันอาจทำให้จำนวน False positive เพิ่มขึ้น ดังนั้นควรใช้ผลจากแบบจำลองร่วมกับการตรวจสอบซ้ำโดยผู้เชี่ยวชาญก่อนสรุปผลภาคสนาม

5.3 แนวทางการศึกษาเพิ่มเติม

สำหรับแนวทางการศึกษาในอนาคต ควรเพิ่มจำนวนและความหลากหลายของข้อมูล GPR ภาคสนาม พิจารณาการ Pretrain หรือ Domain-adaptive pretraining บนชุดข้อมูล GPR ขนาดใหญ่ ศึกษาผลของค่า Confidence threshold ต่อ Precision และ Recall ขยายการวิเคราะห์ไปสู่ข้อมูล GPR แบบสามมิติ และทดสอบแบบจำลองกับพื้นที่อื่นนอกเหนือจากกรุงเทพมหานครและญี่ปุ่น เพื่อประเมินความสามารถในการใช้งานกับสภาพชั้นดินและสภาพแวดล้อมที่หลากหลายมากขึ้น

เอกสารอ้างอิง

- [1] Kuwano, R., Kuwano, J., Sera, Y., Ihara, T., Kozai, N. (2021). Research and Development of Sinking Hazard Assessment and Rational Under-Surface Cavity Countermeasures. *New Road Technology Conference*, Report No. 30-5.
- [2] Thitimakorn, T., Kampananon, N., Jongjaiwanichkit, N., Kupongsak, S. (2016). Subsurface void detection under the road surface using ground penetrating radar (GPR), a case study in the Bangkok metropolitan area, Thailand. *Geo-Engineering*, 7(2), 1–9.
- [3] Davis, J. L., Annan, A. P. (1989). Ground penetrating radar for high resolution mapping of soil and rock stratigraphy. *Geophysical Prospecting*, 37, 531–551.
- [4] Hou, F., Rui, X., Fan, X., Zhang, H. (2022). A Review of GPR Activities in Civil Infrastructures: Data Analysis and Applications. *Remote Sensing*, 14, 5972.
- [5] Neal, A. (2004). Ground-penetrating radar and its use in sedimentology: Principles, problems and progress. *Earth-Science Reviews*, 66, 261–330.
- [6] Zhou, L., Yu, D., Wang, Z., Wang, X. (2019). Soil Water Content Estimation Using High-Frequency Ground Penetrating Radar. *Water*, 11, 1036.
- [7] Ni, Z.-K., Zhao, D., Ye, S., Fang, G. (2020). City road cavity detection using YOLOv3 for ground-penetrating radar. *Proceedings of the 2020 Symposium on the Application of Geophysics to Engineering and Environmental Problems*.
- [8] Gao, Y., Xu, Y., Zhang, X., Yin, C., Quan, L., Tian, B. (2025). Research on internal structural diseases of pavement with GPR based on deep learning network. SSRN.
- [9] Kan, Q., Liu, X., Meng, A., Yu, L. (2024). Intelligent Recognition of Road Internal Void Using Ground-Penetrating Radar. *Applied Sciences*, 14, 11848.
- [10] Yan, Y., Jiao, G., Cui, M., Ni, L. (2025). The Lightweight Method of Ground Penetrating Radar (GPR) Hidden Defect Detection Based on SESM-YOLO. *Buildings*, 15, 2345.
- [11] Nguyen, T. S., Ngamcharoen, K., Likitlersuang, S. (2023). Statistical Characterisation of the Geotechnical Properties of Bangkok Subsoil. *Geotechnical and Geological Engineering*, 41, 2043–2063.
- [12] Mairaing, W., Amonkul, C. (2010). Soft Bangkok Clay Zoning. EIT-Japan Symposium on Engineering for Geo-Hazards: Earthquakes and Landslides-Surface and Subsurface Structures, Bangkok, Thailand.
- [13] Bergado, D. T., Balasubramaniam, A. S., Fannin, R. J., Holtz, R. D. (2002). Prefabricated vertical drains (PVDs) in soft Bangkok clay: A case study of the new Bangkok International Airport project. *Canadian Geotechnical Journal*, 39, 304–315.
- [14] Phutthananon, C., Kongkitkul, W., Cheamsuphakit, A., Seedown, W., Silakub, H., Yamashina, M., Shinohara, J. and Kinoshita, N. (2025). Research on the applicability of high-precision underground exploration technology to public roads in Bangkok: Part 2 – Risk assessment of cavities beneath concrete pavement. *The 30th National Convention on Civil Engineering*, Prachuap Khiri Khan, Thailand.
- [15] Warren, C., Giannopoulos, A., Giannakis, I. (2016). gprMax Open-source software to simulate electromagnetic wave propagation for Ground Penetrating Radar. *Computer Physics Communications*, 209, 163–170.
- [16] Bianchini Ciampoli, L., Tosti, F., Economou, N., Benedetto, F. (2019). Signal Processing of GPR Data for Road Surveys. *Geosciences*, 9, 96.
- [17] Qiao, M., Wang, X., Hou, R. (2023). Case Study: Validation of the Spectral-Analysis-of-Surface-Waves Method for Concrete Pavement Condition Evaluation. *Applied Sciences*, 13, 11410.
- [18] Solla, M., Pérez-Gracia, V., Fontul, S. (2021). A Review of GPR Application on Transport Infrastructures: Troubleshooting and Best Practices. *Remote Sensing*, 13, 672.
- [19] Lombardi, F., Ortuani, B., Facchi, A., Lualdi, M. (2022). Assessing the Perspectives of Ground Penetrating Radar for Precision Farming. *Remote Sensing*, 14, 6066.
- [20] Jegham, N., Koh, C. Y., Abdelatti, M., Hendawi, A. (2025). YOLO Evolution: A Comprehensive Benchmark and Architectural Review of YOLOv12, YOLOv11, and Their Previous Versions. *arXiv*.

- [21] Siméoni, O., Vo, H. V., Seitzer, M., Baldassarre, F., Oquab, M., et al. (2025). DINOv3. *arXiv*.
- [22] Arya, D., Maeda, H., Ghosh, S. K., Toshniwal, D., Omata, H., Kashiya, T., Sekimoto, Y. (2022). Crowdsensing-based Road Damage Detection Challenge (CRDDC'2022). *arXiv*.
- [23] Li, Y., Miao, N., Ma, L., Shuang, F., Huang, X. (2023). Transformer for Object Detection: Review and Benchmark. *Engineering Applications of Artificial Intelligence*, 126, 10702.